

大学生科研训练计划（SRTP）项目结题报告

项目名称：面向机器人柔性磨削的检索增强生成（RAG）知识问答系统构建与优化

所属学科：机械类（0802）· 计算机类（0809）


一、项目研究的目的、意义

制造业是国民经济的支柱产业，机器人柔性磨削作为航空发动机叶片、涡轮盘等关键零部件精密加工的核心工艺，涉及材料科学、力学、控制工程、计算机科学等多学科交叉知识。目前，该领域的工艺参数、设备规范、研究成果等知识高度分散于学术论文、技术报告和企业内部文档中，科研人员和工程师在获取准确、系统的专业知识时面临效率低下的困境。

通用大语言模型（Large Language Model, LLM）虽具备强大的语言理解和生成能力，但在专业领域的问答中常出现“幻觉”（Hallucination）现象——生成看似合理但实际错误的回答。检索增强生成（Retrieval-Augmented Generation, RAG）技术通过在生成回答前检索外部知识库中的权威文档，有效缓解了这一问题。

本项目面向机器人柔性磨削这一垂直领域，构建了包含 1175 篇学术论文的结构化知识库，设计了基于多维分类体系的混合检索策略，并搭建了 RAG 原型系统。项目成果可为该领域的研究人员和工程师提供高效、准确的专业知识服务，同时为制造垂直领域的 RAG 系统构建提供方法参考。

1175 论文总数 去重后（已删除72篇无关）	100% 分类覆盖率 1175/1175篇已标注五维信息	172 中文摘要 14.6% 已覆盖	493 英文摘要 42.0%	1988-2026 时间跨度 近5年 319篇 (27%)	81 分类路径 6维度 × 61条(path)
-------------------------------	------------------------------------	--------------------------	----------------------	-------------------------------------	-------------------------------




二、项目创新点（或特色）

1. 五维结构化知识分类体系

针对机器人磨削领域的特点，设计了 L1 工艺领域 → L2 工艺方式 → L3 研究主题 → L4 应用场景 → L5 加工材料的五层分类标签体系。不同于传统的平铺式关键词标注，该体系实现了论文的多维度、层级化组织，为结构化检索提

供了知识基础。



2. 基于领域分类的结构化混合检索策略

提出了一种融合多维分类过滤、语义向量匹配和摘要加权重排序的混合检索策略。实验表明，相比朴素全文检索，该策略在 Recall@5 指标上提升 29%，在工艺查询类问题上提升 61%，验证了领域知识结构对 RAG 检索质量具有显著的增强效果。



3. 多源数据采集与自动化知识库构建管线

结合 Zotero 文献管理工具导出的结构化数据与 OpenAlex 开放学术 API 的自动化爬取，建立了从数据采集、元数据补全、自动分类到前端可视化的全流程知识库构建管线，实现了知识库的可持续更新。

4. 多维知识可视化探索系统

构建了包含 D3 径向树、层级导图、ECharts 径向树、3D 知识星系在内的 6 种交互式可视化工具，支持用户从不同维度探索知识体系，突破了传统论文检索系统单一列表展示的局限。




三、项目研究的主要内容

1. 机器人柔性磨削知识库构建


（1）数据采集：从华中科技大学、西北工业大学、重庆大学三所高校的 Zotero 文献库导出 172 篇论文的结构化元数据；通过 OpenAlex API，以 20 组关键词检索并爬取补充论文，最终形成 1247 篇论文的数据集。



（2）五维分类体系设计：基于机器人磨削领域的知识结构，定义 L1-L5 五层分类标签，建立中英文双语关键词匹配规则（taxonomy.py），实现对论文的自动分类标注。



（3）学术会议与期刊生态：提取论文发表的 80+ 个期刊/会议信息，整合影响因子、出版方、研究范围等元数据，构建学术生态数据库。



2. RAG 检索策略设计与实验

(1) 基线策略（朴素 BM25）：对用户查询进行分词后，在全量论文集中进行词频匹配。


(2) 结构化检索策略：先利用多维标签判定查询所属的知识类别，再在匹配类别子集内执行检索。

(3) 混合检索策略：在结构化过滤基础上，引入摘要关键词命中加权机制，对分类匹配与语义匹配进行综合打分。

(4) 对比实验：构建 20 个典型工艺查询问题（覆盖工艺查询、材料对比、趋势分析、定义解释四类），以 Recall@K 和 MRR 为评价指标，对三种策略进行系统对比。



LLM 决策逻辑详解



数据流全景



RAG 检索增强生成系统架构

3. 向量数据库构建

基于阿里云百炼 text-embedding-v3 模型（1024 维），将 1247 篇论文向量化存储至 ChromaDB，构建支持语义检索的向量数据库。该向量库可导出并直接用于 RAG 系统的检索层。

```
=====
🔧 P0-1: 构建论文向量数据库
=====
🔑 API Key: sk-e8b26...a56f
📦 Embedding 模型: text-embedding-v3


📁 加载论文数据...
✓ 从 papers_enriched_updated.json 加载 0 篇
✓ 从 papers_enriched_updated.json 加载 0 篇
✓ 从 papers_enriched.json 加载 0 篇
✓ 从 papers.json 加载 0 篇
🇺🇦 总计 1175 篇论文
```

```
命令提示符
[790/1175] 已写入 790 条
[800/1175] 已写入 800 条
[810/1175] 已写入 810 条
[820/1175] 已写入 820 条
[830/1175] 已写入 830 条
[840/1175] 已写入 840 条
[850/1175] 已写入 850 条
[860/1175] 已写入 860 条
[870/1175] 已写入 870 条
[880/1175] 已写入 880 条
[890/1175] 已写入 890 条
[900/1175] 已写入 900 条
[910/1175] 已写入 910 条
[920/1175] 已写入 920 条
[930/1175] 已写入 930 条
[940/1175] 已写入 940 条
[950/1175] 已写入 950 条
[960/1175] 已写入 960 条
[970/1175] 已写入 970 条
[980/1175] 已写入 980 条
[990/1175] 已写入 990 条
[1000/1175] 已写入 1000 条
[1010/1175] 已写入 1010 条
[1020/1175] 已写入 1020 条
[1030/1175] 已写入 1030 条
[1040/1175] 已写入 1040 条
[1050/1175] 已写入 1050 条
[1060/1175] 已写入 1060 条
[1070/1175] 已写入 1070 条
[1080/1175] 已写入 1080 条
[1090/1175] 已写入 1090 条
[1100/1175] 已写入 1100 条
[1110/1175] 已写入 1110 条
[1120/1175] 已写入 1120 条
[1130/1175] 已写入 1130 条
[1140/1175] 已写入 1140 条
[1150/1175] 已写入 1150 条
[1160/1175] 已写入 1160 条
[1170/1175] 已写入 1170 条
[1175/1175] 已写入 1175 条

=====
完成! ChromaDB 共 1175 条向量
存储位置: C:\Users\VINEL\PycharmProjects\PythonProject\app\chroma_db
测试检索:
python -c "
import chromadb
c = chromadb.PersistentClient(path='C:\Users\VINEL\PycharmProjects\PythonProject\app\chroma_db')
col = c.get_collection('papers_full')
print(col.count())
"
```

4. 知识库可视化系统

开发了单页滚动式知识导航主页（index.html），集成粒子动画 Hero 区、3D 知识星球、D3 径向知识图谱缩略图、3D 地球会议标注、论文库三栏检索、横向研究时间轴等 6 个功能模块，并提供 3 种思维导图独立页面（D3 径向树、vis-network 层级导图、ECharts 径向树）。



四、项目研究过程与方法

第一阶段：文献调研与数据采集

调研机器人柔性磨削领域的研究现状，确定知识库的范围和分类框架。从 Zotero 导出结构化文献数据，编写 Python 脚本 (zotero_parser.py) 解析 CSV 格式的论文元数据。同时，利用 OpenAlex API 编写爬虫脚本 (crawl_papers.py)，以 "robotic belt grinding""robot abrasive belt grinding" 等 20 组中英文关键词检索补充论文，通过 DOI 去重后合并至主数据集。



第二阶段：知识库构建与分类

设计五维分类规则 (taxonomy.py)，为每个维度 (L1-L5) 建立中英文关键

词映射表。编写分类引擎，对每篇论文的标题、摘要、关键词进行匹配，自动分配五维标签。同时编写会议/期刊数据提取脚本（build_conferences.py），统计各期刊的论文数量、年份分布和研究方向趋势。

第三阶段：检索策略设计与实验

参考 BM25 算法的核心思想，设计朴素全文检索、结构化过滤检索和混合加权检索三种策略。构建 20 个测试问题及其预期匹配论文 ID 列表，编写实验脚本（experiment_retrieval.py）在 1247 篇论文上运行对比实验，计算 Recall@5、Recall@10 和 MRR 指标。

```

🔍 §三(3) - 5个测试查询 Top-3
=====

🔍 钛合金叶片磨削表面粗糙度控制
#1 [dist=0.4946] 3D printed compliance tool incorporated internal-impeller structure fo
2024 | 柔顺磨削, 3D打印工具, 内嵌叶轮冷却, 钛合金磨削, 界面热控制
#2 [dist=0.5100] Titanium alloys surface integrity of belt grinding considering differe
2022 | 钛合金, 宽砂带磨削, 表面完整性, 加工轨迹规划, 残余应力
#3 [dist=0.5658] A novel selected force controlling method for improving robotic grind
2022 | 机器人磨削, 选力控制, 自适应阻抗控制, 复杂曲面叶片, 磨削力控制

🔍 砂带磨损状态监测方法
#1 [dist=0.4206] A novel model for monitoring wear state of a belt in grinding GH4169 a
2025 | 砂带磨损监测, 迁移学习, GH4169合金, 多工况磨削, 特征标准化
#2 [dist=0.4623] An online belt wear monitoring method for abrasive belt grinding under
|
#3 [dist=0.4631] Condition monitoring and mechanism analysis of belt wear in robotic gr
2023 | 声发射监测, 砂带磨损, 机器人磨削, TC4合金, 表面质量控制

🔍 机器人磨削力控制策略
#1 [dist=0.4292] Application of novel force control strategies to enhance robotic abras
2019 | 机器人砂带磨削, 力-位混合控制, PI/PD控制, 航空发动机叶片, 力反馈控制
#2 [dist=0.4474] Region-Based Force Control Strategy for Improving Profile Accuracy of
2024 | 区域力控制, 七轴联动机器人, 叶片磨削, 自适应阻抗控制, 轮廓精度
#3 [dist=0.4503] Analysis and assessment of robotic belt grinding mechanisms by force m
2018 | 机器人磨削, 力控制, 切削力模型, 表面粗糙度, 带式磨削

🔍 高温合金 Inconel 718 磨削参数
#1 [dist=0.4642] Thermal Analysis of Belt Grinding Process of Nickel-Based Superalloy I
|
#2 [dist=0.4764] A new force-depth model for robotic abrasive belt grinding and confirm
2023 | 砂带磨削, 力-深度模型, Inconel 718, 机器人磨削, 材料去除建模
#3 [dist=0.4819] Comprehensive investigations into the force and thermal characteristic
|

🔍 磨削残余应力预测模型
#1 [dist=0.3171] A prediction model of residual stress for belt-grinding blade based on
2022 | 残余应力预测, 带式磨削, 磨粒几何形貌, 渐进磨损, 航空发动机叶片
#2 [dist=0.4174] Prediction method of residual stress and deformation in belt grinding
2025 | 薄壁环形零件, 带式磨削, 残余应力预测, 变形预测, 支持向量回归
#3 [dist=0.4830] Prediction and experimental research of abrasive belt grinding residua
2021 |
```

第四阶段：可视化系统开发

基于 HTML5/CSS3/JavaScript 技术栈，使用 D3.js（径向树）、Three.js（3D 星系/地球）、vis-network（层级导图）、ECharts（径向树）等开源可视化库，开发单页滚动式知识导航主页和独立导图页面。所有第三方库均下载至本地，实现零 CDN 依赖。

第五阶段：向量数据库与 RAG 管线（进行中）

安装配置 ChromaDB，编写向量库构建脚本（build_vector_db.py），调用阿里云百炼 text-embedding-v3 API 对论文进行向量化处理。设计 RAG 检索-生成管线架构，包括 embedding 查询、ChromaDB 检索、结构化重排序和百炼 qwen-plus 生成四个模块。

第一阶段：文献调研与数据采集 → 数据文件全景		
数据文件	用途	规模
papers_enriched_updated.json	主数据（全字段）	1175篇完整元数据
papers_classified.json	前端检索切片	1175篇精简字段
papers_index.json	按ID查询	1175篇 by_id索引
category_index.json	分类索引	81条path × 6维度
mindmap_stats.json / mindmaps_five.json	导图数据	5维 × 全部分类
experiment_results.json	检索实验	3策略 × Recall/MRR
conferences/conferences.json	会议数据库	224期刊 + 23会议
第二~第五阶段对应素材		
阶段	内容	截屏来源
第二阶段	分类体系设计	本页 §二 分类树 + mindmaps.html
第三阶段	检索策略实验	本页 §二 三策略对比 + experiment.html
第四阶段	可视化系统开发	本页 §二 6种可视化链接 + index.html
第五阶段	向量数据库与RAG	● 同学提供：build_vector_db 终端截图 + ChromaDB 文件夹截图

五、项目完成预期目标情况

预期目标	完成情况	说明
知识库构建：整理制造工艺、设备与标准文档	✔ 超额完成	构建 1175 篇论文结构化知识库 + 80+ 期刊/会议数据库，超出原计划 172 篇的规模
RAG 系统搭建：实现检索增强生成流程	⚠ 部分完成	检索层（向量库 + 混合检索策略）已实现并完成实验验证；生成层（百炼 qwen-plus 对接）进行中
优化与改进：检索策略、向量模型、提示词设计实验	✔ 部分完成	完成三种检索策略对比实验，验证结构化检索提升 29%；向量模型选型和 chunk 策略实验进行中
应用与展示：系统测试与演示	✔ 完成	开发 6 种交互式可视化工具 + 单页导航主

	预期目标	完成情况	说明	
示	页 + 实验数据展示页			
	知识库构建 1175篇+81条分类路径	RAG系统搭建 检索库构建, 生成器进行中	检索优化实验 3策略对比, 提升28.9%	可视化展示 6种交互式工具+主页

六、项目成果简介

1. 机器人柔性磨削结构化知识库

收录 1247 篇学术论文（1988-2026），覆盖 80+ 个期刊和会议。每篇论文标注 L1-L5 五维分类标签，附带中英文关键词、摘要和原文链接。数据集以 JSON 格式存储，支持程序化访问和增量更新。

2. 五维分类体系

涵盖 L1 工艺领域（机器人磨削/非机器人专用磨削）、L2 工艺方式（砂带/抛光/磁盘磨削等）、L3 研究主题（表面质量/力控制/轨迹规划等 10 个子类）、L4 应用场景（航空航天/船舶/汽车等）、L5 加工材料（钛合金/高温合金/陶瓷等）。

3. 混合检索策略实验验证

在 20 个测试问题上的实验表明：混合检索（分类过滤+摘要加权）的 Recall@5 为 13.5%，较朴素 BM25 提升 29%；MRR 从 0.391 提升至 0.507（+30%）。工艺查询类问题提升最为显著（+61%），验证了领域知识结构对检索质量的正向增强效果。

4. 多维知识可视化系统

开发了包含单页滚动导航主页、3 种思维导图、3D 知识星系、3D 会议地

球、研究时间轴、论文库三栏检索在内的完整 Web 可视化系统，全部采用本地化部署，支持离线使用。

5. 学术会议/期刊生态数据库

收录 80+ 个期刊和会议的论文分布、年份趋势、影响因子、研究方向和官方网站等信息，以 3D 地球标注会议举办地，提供交互式浏览。





七、项目研究工作的分析与总结

1. 取得的进展

本项目围绕"制造垂直领域知识增强的 Chatbot 构建与优化"这一课题，系统性地完成了知识库构建、分类体系设计、检索策略实验和可视化系统开发四个方面的研究工作。

项目的核心贡献在于：（1）提出并验证了基于领域分类的结构化混合检索策略，实验证明该策略在专业领域问答场景中较朴素检索具有显著优势；（2）构建了可复用的知识库构建管线，从数据采集、自动分类到前端展示形成完整闭环；（3）开发了多维可视化系统，为知识探索提供了超越传统列表检索的交互体验。

2. 后续工作方向

（1）完成 ChromaDB 向量库构建，在真实 embedding 环境下复现检索策略对比实验；（2）对接百炼 qwen-plus 完成生成层，实现端到端的 RAG 问答原型；（3）设计并标注 50 个 QA pair 评估数据集，开展系统的检索与生成质量评估；（4）优化 prompt 模板设计，针对不同问题类型（工艺查询/材料对比

/趋势分析/定义解释）开发专用模板；（5）开发 Web 对话界面，实现完整的用户交互体验。



3. 研究收获

通过本项目，团队成员在以下方面获得了系统训练：学术文献的批量采集与数据处理、领域知识分类体系的设计方法、信息检索算法（BM25/向量检索）的原理与实现、检索策略的对比实验设计与评估方法、基于 HTML5/JavaScript 的 Web 可视化开发、RAG 系统的架构设计与工程实现。这些能力为今后从事智能制造、知识工程或 AI 应用方向的研究工作奠定了坚实基础。



二、项目研究存在的问题、建议

存在的问题

（1）知识库覆盖面的结构性偏差。当前 1175 篇论文主要来源于 OpenAlex 英文数据库，中文文献（尤其是学位论文和企业技术报告）覆盖率较低。机器人磨削领域有大量研究成果发表于中文期刊和会议，这部分文献的缺失可能导致知识库对国内研究现状的反映不够全面。

（2）分类体系对新兴方向的适应性不足。五维分类依赖关键词规则匹配，

当论文涉及新兴交叉方向（如基于深度学习的磨削参数优化、数字孪生驱动的工艺监控）时，预定义关键词表难以覆盖，导致分类遗漏或归类不当。此外，L3（研究主题）子类较丰富，而 L4（应用场景）、L5（加工材料）的粒度相对稀疏，各维度间的信息密度不均衡。

（3）检索评估的标注成本与主观性问题。20 个测试问题的 ground truth（预期匹配论文列表）由项目成员人工标注，标注者自身的知识背景会影响判断，不同标注者之间的一致性未经验证。将评估规模扩展至 50-100 个问题，人工标注的成本和主观性将进一步凸显。

（4）工程模块间的耦合度偏高。数据采集、分类引擎、可视化系统、向量数据库各模块由不同成员独立开发，缺乏统一的接口规范和数据格式约定。部分模块间的数据传递依赖手动导出/导入，自动化程度不足，给后续维护和功能扩展带来困难。

（5）计算资源与 API 成本约束。向量化 1247 篇论文需调用商用 embedding API（阿里云百炼 text-embedding-v3），产生一定的调用费用。在有限的 SRTP 经费和时间框架下，这制约了大规模消融实验（如对比不同 embedding 模型、不同 chunk 策略）的开展。

建议

（1）知识库建设：引入半自动化标注与增量更新机制。建议后续研究利用主动学习或弱监督方法辅助论文分类，降低人工标注成本。同时建立增量更新管道——定期扫描新增论文并自动归类，保持知识库的时效性。可考虑对接 arXiv API 或 Semantic Scholar API 扩展数据源，弥补中文文献的缺口。

（2）检索策略：在真实向量环境下完成完整验证。当前实验基于 BM25 词频匹配模拟，建议在 ChromaDB 向量库建成后，在真实 embedding 检索环境下复现全部对比实验，并增加语义相似度作为辅助评价指标。同时建议引入标准 IR 数据集构建方法（如 pooling 策略），提升评估的规范性。

(3) 工程架构：引入成熟框架，降低维护成本。建议将自研的检索-重排序管线迁移至 LangChain 或 LlamaIndex 等成熟 RAG 框架上，减少重复造轮子，同时获得更完善的日志、监控和评估工具链。各模块间的数据接口应统一为 JSON Schema 并文档化。

(4) SRTP 项目管理：加强初期调研与中期审查。本项目在初期阶段对 embedding 模型选型和向量数据库方案的调研不够充分，导致后期调整方案产生额外成本。建议后续 SRTP 项目在立项阶段完成充分的技术选型对比实验，并在中期增设代码审查和集成测试环节，尽早发现模块间的接口不一致问题。

(5) 跨学科协作：明确分工与知识传递机制。本项目涉及机械工程与计算机科学两个学科的交叉，团队成员的背景差异较大。建议跨学科 SRTP 项目在启动阶段明确各成员的分工边界，并建立定期知识传递机制（如周会技术分享），确保各成员对项目整体架构有一致理解，避免信息孤岛。